Conhecendo o Tidyverse

dplyr

Fernando de Pol Mayer (LEG/DEST/UFPR)
2022-03-22

R for Data Science

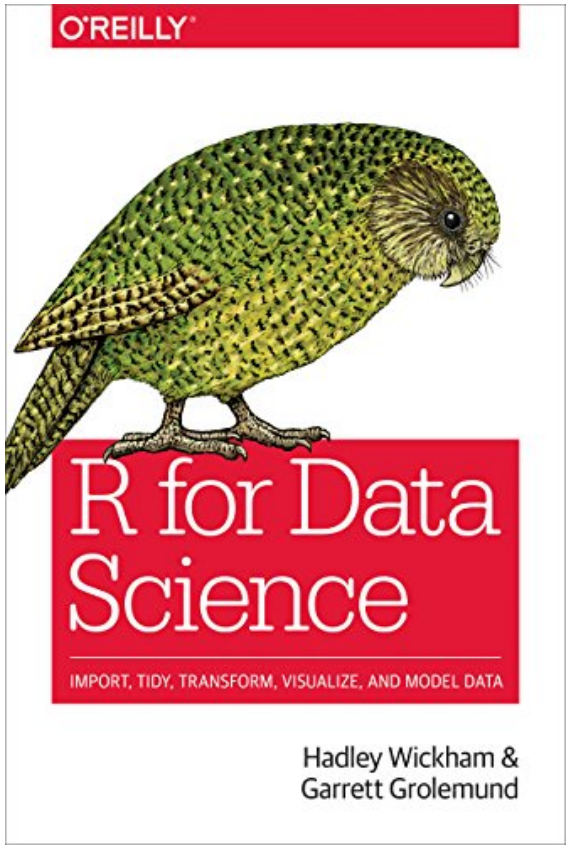

R for Data Science, a principal referência sobre o emprego da linguagem R em ciência de dados.

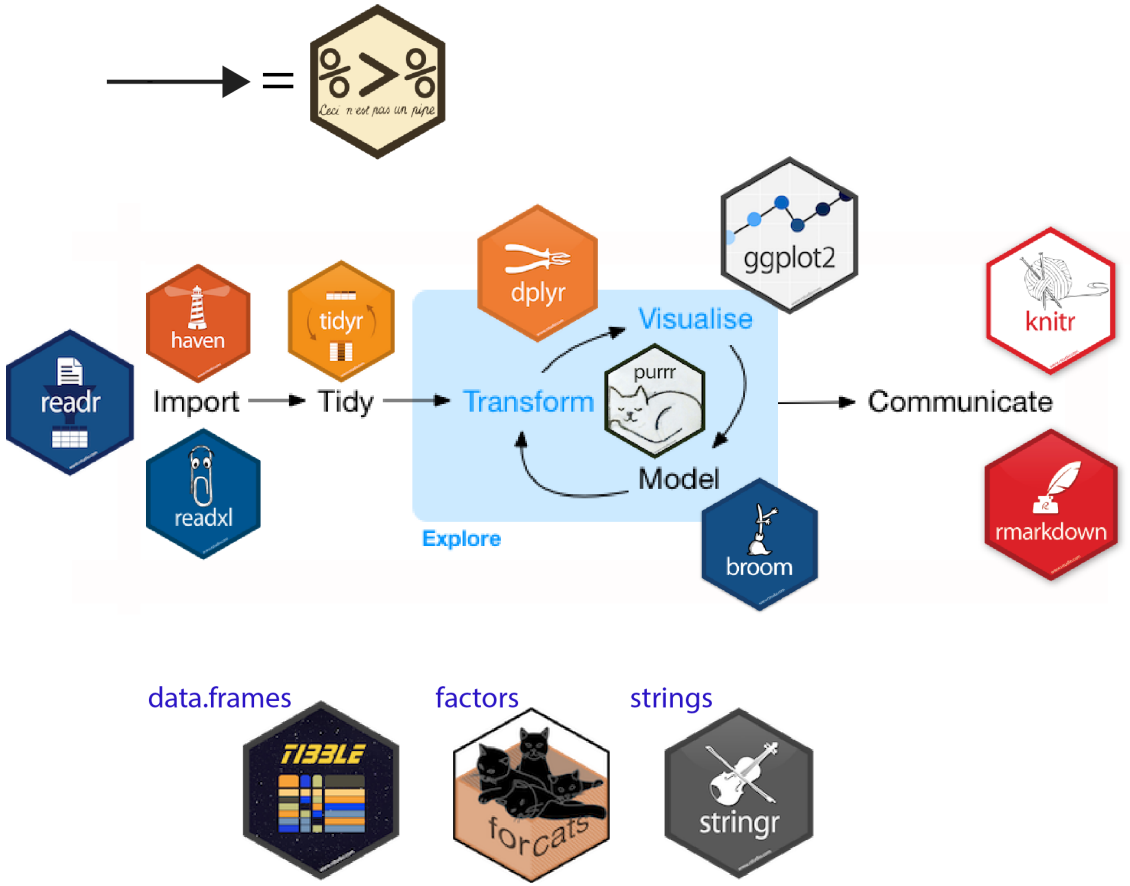

Workflow de ciência de dados com o {tidyverse}. Fonte: https://oliviergimenez.github.io/intro_tidyverse/#7

{dplyr}

Um overview do {dplyr}

- Depois dos dados arrumados, é a hora começar conhecê-los!
- Começa a fase de **análise exploratória de dados** (AED).
- Os dados são explorados para:
  - Conhecer as (propriedades das) variáveis.
  - Determinar medidas descritivas.
  - Comparar grupos.
  - Quantificar relações entre variáveis.
  - Extrair padrões.
  - Detectar ameaças e corrigir problemas.
- AED envolve inúmeras operações.
- É preciso conhecê-las e ser criativo para aplicar da melhor forma.

Detalhes do `dplyr`

- O `dplyr` é a **gramática** para manipulação de dados.
- Tem um conjunto **consistente** de verbos para atuar sobre tabelas.
  - Verbos: `mutate()`, `select()`, `filter()`, `arrange()`, `summarise()`, `slice()`, `rename()`, etc.
  - Agrupamento: `group_by()` e `ungroup()`.
  - Junções: `inner_join()`, `full_join()`, `left_join()` e `right_join()`.
  - Funções resumo: `n()`, `n_distinct()`, `first()`, `last()`, `nth()`, etc.
  - E muito mais no cartão de referência: https://github.com/rstudio/cheatsheets/blob/main/data-transformation.pdf
- Documentação:
  - https://dplyr.tidyverse.org/.
  - https://r4ds.had.co.nz/relational-data.html.
  - https://cran.r-project.org/package=dplyr

Criação de um `tibble`

	matrícula	nome	curso	prova1	prova2	prova3	faltas
1	256	João	Mat	80	90	80	4
2	487	Vanessa	Mat	75	75	75	4
3	965	Tiago	Est	95	80	75	0
4	125	Luana	Est	70	85	50	8
5	458	Gisele	Est	45	50		16
6	874	Pedro	Mat	55	75	90	0
7	963	André	Est	30		30	20

Uma tabela com dados fictícios sobre alunos e seus desempenhos.

Criação de um `tibble`

Criação por colunas

```
library(tidyverse)

# Tabela com alunos do curso de
# Matemática e de Estatística.
df1 <- tibble(
    matricula = c(256, 487, 965,
                  125, 458, 874, 963),
    nome = c("João", "Vanessa", "Tiago",
             "Luana", "Gisele", "Pedro",
             "André"),
    curso = c("Mat", "Mat", "Est", "Est",
              "Est", "Mat", "Est"),
    prova1 = c(80, 75, 95, 70, 45, 55, 30),
    prova2 = c(90, 75, 80, 85, 50, 75, NA),
    prova3 = c(80, 75, 75, 50, NA, 90, 30),
    faltas = c(4, 4, 0, 8, 16, 0, 20))
```

```
df1
```

```
# # A tibble: 7 × 7
#   matricula nome    curso prova1 prova2 prova3 faltas
#       <dbl> <chr>   <chr>  <dbl>  <dbl>  <dbl>  <dbl>
# 1       256 João    Mat       80     90     80      4
# 2       487 Vanessa Mat       75     75     75      4
# 3       965 Tiago   Est       95     80     75      0
# 4       125 Luana   Est       70     85     50      8
# 5       458 Gisele  Est       45     50     NA     16
# 6       874 Pedro   Mat       55     75     90      0
# 7       963 André   Est       30     NA     30     20
```

Ordenação

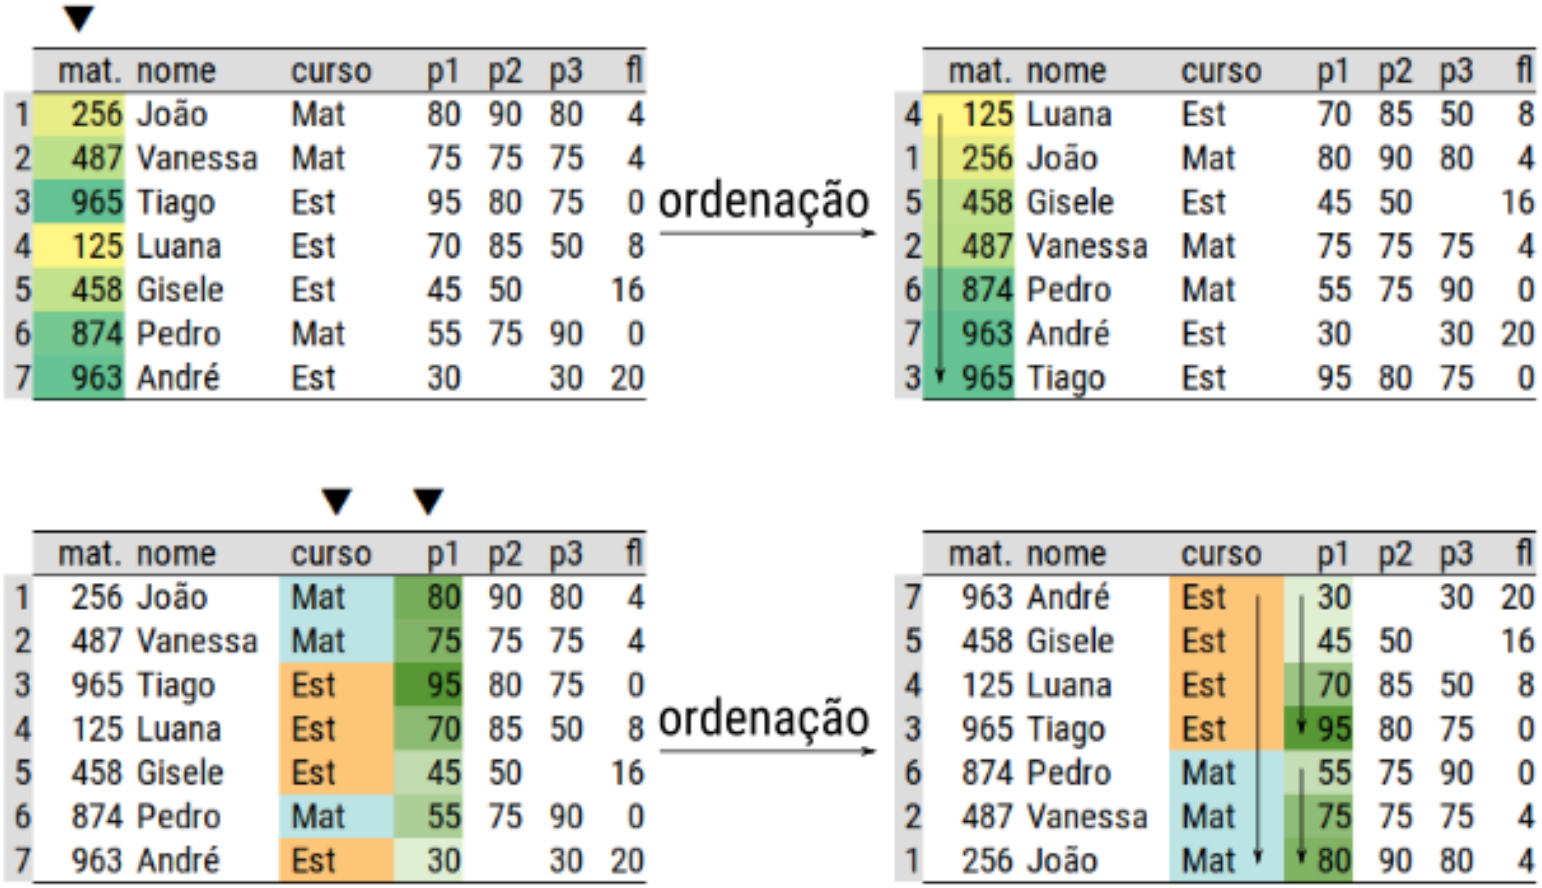

	mat.	nome	curso	p1	p2	p3	fl
1	256	João	Mat	80	90	80	4
2	487	Vanessa	Mat	75	75	75	4
3	965	Tiago	Est	95	80	75	0
4	125	Luana	Est	70	85	50	8
5	458	Gisele	Est	45	50		16
6	874	Pedro	Mat	55	75	90	0
7	963	André	Est	30		30	20

	mat.	nome	curso	p1	p2	p3	fl
4	125	Luana	Est	70	85	50	8
1	256	João	Mat	80	90	80	4
5	458	Gisele	Est	45	50		16
2	487	Vanessa	Mat	75	75	75	4
6	874	Pedro	Mat	55	75	90	0
7	963	André	Est	30		30	20
3	965	Tiago	Est	95	80	75	0

	mat.	nome	curso	p1	p2	p3	fl
1	256	João	Mat	80	90	80	4
2	487	Vanessa	Mat	75	75	75	4
3	965	Tiago	Est	95	80	75	0
4	125	Luana	Est	70	85	50	8
5	458	Gisele	Est	45	50		16
6	874	Pedro	Mat	55	75	90	0
7	963	André	Est	30		30	20

	mat.	nome	curso	p1	p2	p3	fl
7	963	André	Est	30		30	20
5	458	Gisele	Est	45	50		16
4	125	Luana	Est	70	85	50	8
3	965	Tiago	Est	95	80	75	0
6	874	Pedro	Mat	55	75	90	0
2	487	Vanessa	Mat	75	75	75	4
1	256	João	Mat	80	90	80	4

Ordenação dos registros de uma tabela.

Ordenação

Por uma variável

```
df1 %>%
    arrange(matricula)
```

```
# # A tibble: 7 × 7
#   matricula nome    curso prova1 prova2 prova3 faltas
#       <dbl> <chr>   <chr>  <dbl>  <dbl>  <dbl>  <dbl>
# 1       125 Luana   Est       70     85     50      8
# 2       256 João    Mat       80     90     80      4
# 3       458 Gisele  Est       45     50     NA     16
# 4       487 Vanessa Mat       75     75     75      4
# 5       874 Pedro   Mat       55     75     90      0
# 6       963 André   Est       30     NA     30     20
# 7       965 Tiago   Est       95     80     75      0
```

Por duas ou mais variáveis

```
df1 %>%
    arrange(curso, desc(prova1))
```

```
# # A tibble: 7 × 7
#   matricula nome    curso prova1 prova2 prova3 faltas
#       <dbl> <chr>   <chr>  <dbl>  <dbl>  <dbl>  <dbl>
# 1       965 Tiago   Est       95     80     75      0
# 2       125 Luana   Est       70     85     50      8
# 3       458 Gisele  Est       45     50     NA     16
# 4       963 André   Est       30     NA     30     20
# 5       256 João    Mat       80     90     80      4
# 6       487 Vanessa Mat       75     75     75      4
# 7       874 Pedro   Mat       55     75     90      0
```

`desc()`: ordenação **decrescente** da variável.

Seleção das variáveis

Seleção pelos nomes

```
df1 %>%
    select(nome, prova1, prova2, prova3)
```

```
# # A tibble: 7 × 4
#   nome    prova1 prova2 prova3
#   <chr>    <dbl>  <dbl>  <dbl>
# 1 João        80     90     80
# 2 Vanessa     75     75     75
# 3 Tiago       95     80     75
# 4 Luana       70     85     50
# 5 Gisele      45     50     NA
# 6 Pedro       55     75     90
# 7 André       30     NA     30
```

```
df1 %>% select(c("nome", "prova1"))
df1 %>% select(-nome, -faltas)
df1 %>% select(prova1:prova3)
```

Seleção pela posição

```
df1 %>%
    select(1:3)
```

```
# # A tibble: 7 × 3
#   matricula nome    curso
#       <dbl> <chr>   <chr>
# 1       256 João    Mat
# 2       487 Vanessa Mat
# 3       965 Tiago   Est
# 4       125 Luana   Est
# 5       458 Gisele  Est
# 6       874 Pedro   Mat
# 7       963 André   Est
```

```
df1 %>% select(1, 4)
df1 %>% select(-1, -4)
```

Seleção das variáveis

Seleção de variáveis por condição

```
df1 %>%
    select(where(is.numeric))
```

```
# # A tibble: 7 × 5
#   matricula prova1 prova2 prova3 faltas
#       <dbl>  <dbl>  <dbl>  <dbl>  <dbl>
# 1       256     80     90     80      4
# 2       487     75     75     75      4
# 3       965     95     80     75      0
# 4       125     70     85     50      8
# 5       458     45     50     NA     16
# 6       874     55     75     90      0
# 7       963     30     NA     30     20
```

```
df1 %>%
    select(!where(is.numeric))
```

Seleção por expressão regular

```
df1 %>%
    select(matches("^prova"))
```

```
# # A tibble: 7 × 3
#   prova1 prova2 prova3
#    <dbl>  <dbl>  <dbl>
# 1     80     90     80
# 2     75     75     75
# 3     95     80     75
# 4     70     85     50
# 5     45     50     NA
# 6     55     75     90
# 7     30     NA     30
```

```
## Nomes que terminam em dígitos
df1 %>%
    select(matches("\\d$"))
## Todos os nomes com 6 caracteres
df1 %>%
    select(matches("^.{6}$"))
```

```
## Outros
df1 %>%
    select(starts_with("pr"))
df1 %>%
    select(ends_with("a"))
df1 %>%
    select(contains("urso"))
```

Fatiamento por linhas

Fatiamento

```
df1 %>%
    slice(3:5)
```

```
# # A tibble: 3 × 7
#   matricula nome   curso prova1 prova2 prova3 faltas
#       <dbl> <chr>  <chr>  <dbl>  <dbl>  <dbl>  <dbl>
# 1       965 Tiago  Est       95     80     75      0
# 2       125 Luana  Est       70     85     50      8
# 3       458 Gisele Est       45     50     NA     16
```

```
df1 %>%
    slice(-(3:5))
df1 %>%
    slice(c(3:4, 1:2))
```

Extremidades

```
# Primeiras linhas (cabeça).
df1 %>%
    head(n = 4)
```

```
# # A tibble: 4 × 7
#   matricula nome    curso prova1 prova2 prova3 faltas
#       <dbl> <chr>   <chr>  <dbl>  <dbl>  <dbl>  <dbl>
# 1       256 João    Mat       80     90     80      4
# 2       487 Vanessa Mat       75     75     75      4
# 3       965 Tiago   Est       95     80     75      0
# 4       125 Luana   Est       70     85     50      8
```

```
# Últimas linhas (cauda).
df1 %>%
    tail(n = 4)
```

Filtros

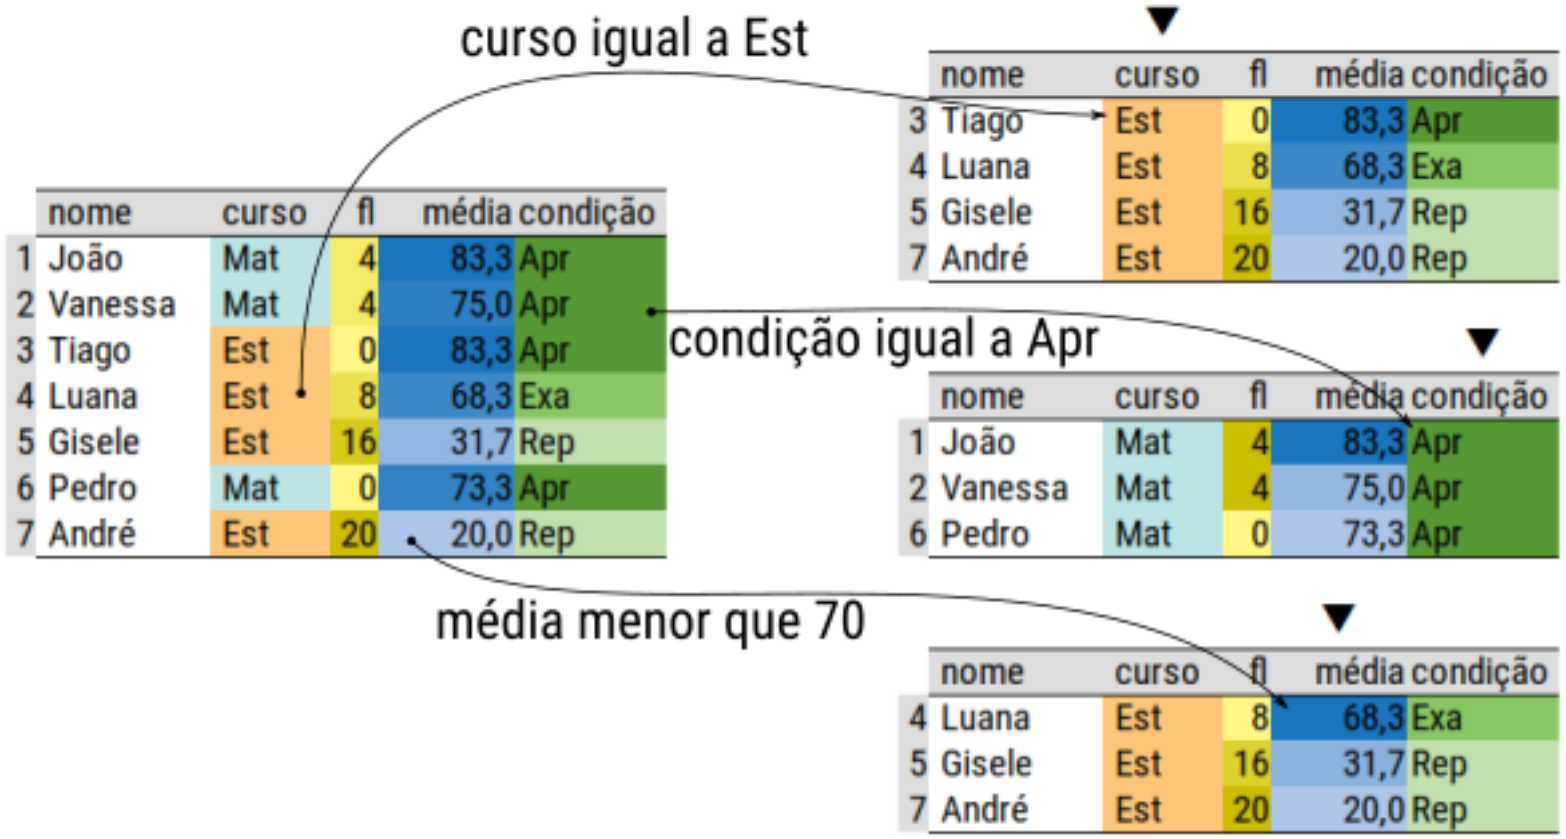

Filtro dos registros de uma tabela.

Filtros

Usando uma variável

```
df1 %>%
    filter(curso == "Est")
```

```
# # A tibble: 4 × 7
#   matricula nome   curso prova1 prova2 prova3 faltas
#       <dbl> <chr>  <chr>  <dbl>  <dbl>  <dbl>  <dbl>
# 1       965 Tiago  Est       95     80     75      0
# 2       125 Luana  Est       70     85     50      8
# 3       458 Gisele Est       45     50     NA     16
# 4       963 André  Est       30     NA     30     20
```

```
df1 %>%
    filter(faltas == 0)
df1 %>%
    filter(faltas != 0)
df1 %>%
    filter(nome %in% c("Luana", "Vanessa"))
## Seleciona colunas que possuem pelo menos um NA
df1 %>%
    select(function(x) any(is.na(x)))
```

Usando duas ou mais

```
df1 %>%
    ## select(curso, prova1:prova3) %>%
    filter(curso == "Est",
           (prova1 + prova2 + prova3)/3 > 70)
```

```
# # A tibble: 1 × 7
#   matricula nome  curso prova1 prova2 prova3 faltas
#       <dbl> <chr> <chr>  <dbl>  <dbl>  <dbl>  <dbl>
# 1       965 Tiago Est       95     80     75      0
```

```
## Note a diferença
df1 %>%
    filter(faltas == 0 & curso == "Est")
df1 %>%
    filter(faltas == 0, curso == "Est")
```

```
## Para reproduzir a figura
df2 <- df1 %>%
    mutate(media = (prova1 + prova2 + prova3)/3,
           condicao = ifelse(media >= 70, "Apr", "Rep"))
df2
df2 %>%
    filter(condicao == "Apr")
df2 %>%
    filter(media < 70)
df2 %>%
    filter(condicao == "Apr" & curso == "Est")
```

Amostragem das observações

Amostra de n elementos

```
# Amostra aleatória das linhas.
df1 %>%
    sample_n(size = 3, replace = FALSE)
```

```
# # A tibble: 3 × 7
#   matricula nome  curso prova1 prova2 prova3 faltas
#       <dbl> <chr> <chr>  <dbl>  <dbl>  <dbl>  <dbl>
# 1       256 João  Mat       80     90     80      4
# 2       125 Luana Est       70     85     50      8
# 3       965 Tiago Est       95     80     75      0
```

Amostra de uma fração p

```
# Amostra aleatória das linhas.
df1 %>%
    sample_frac(size = 0.5, replace = FALSE)
```

```
# # A tibble: 4 × 7
#   matricula nome    curso prova1 prova2 prova3 faltas
#       <dbl> <chr>   <chr>  <dbl>  <dbl>  <dbl>  <dbl>
# 1       487 Vanessa Mat       75     75     75      4
# 2       963 André   Est       30     NA     30     20
# 3       256 João    Mat       80     90     80      4
# 4       965 Tiago   Est       95     80     75      0
```

Renomeação

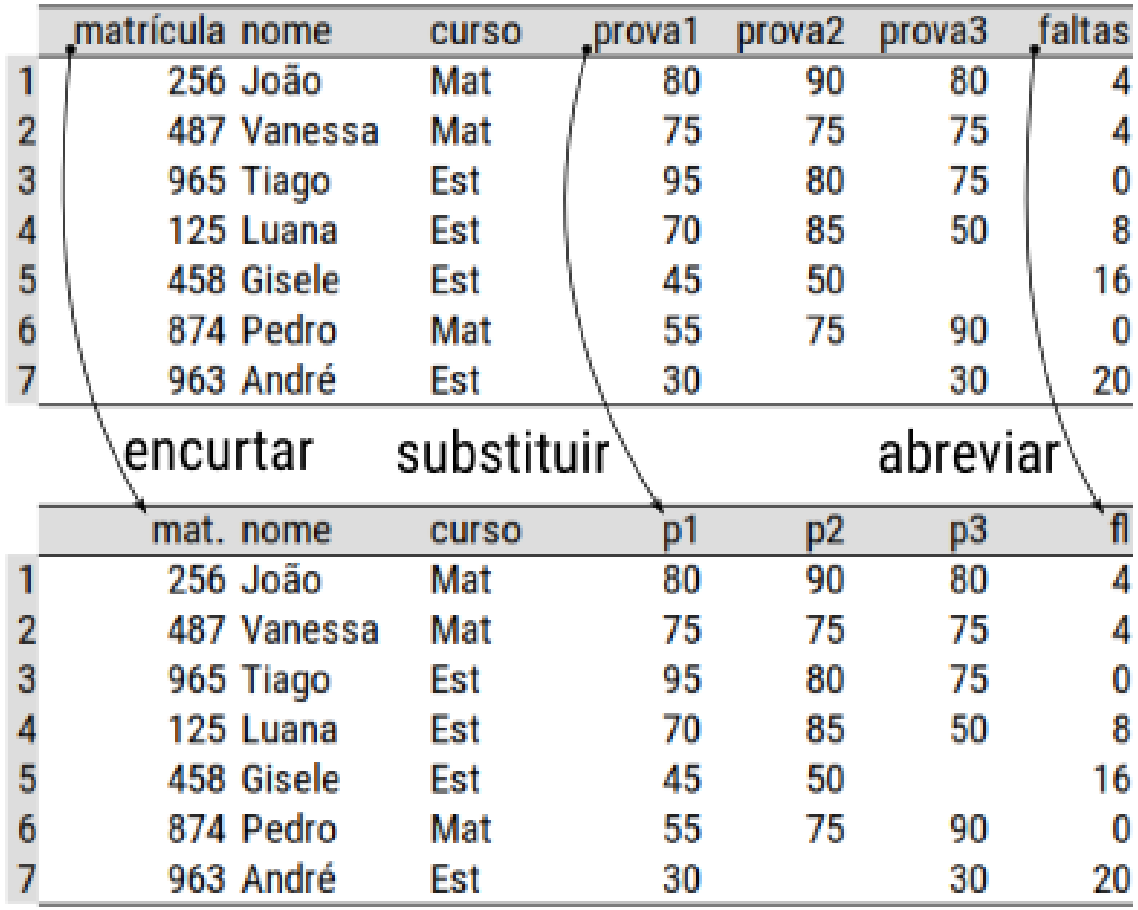

	matrícula	nome	curso	prova1	prova2	prova3	faltas
1	256	João	Mat	80	90	80	4
2	487	Vanessa	Mat	75	75	75	4
3	965	Tiago	Est	95	80	75	0
4	125	Luana	Est	70	85	50	8
5	458	Gisele	Est	45	50		16
6	874	Pedro	Mat	55	75	90	0
7	963	André	Est	30		30	20

	mat.	nome	curso	p1	p2	p3	fl
1	256	João	Mat	80	90	80	4
2	487	Vanessa	Mat	75	75	75	4
3	965	Tiago	Est	95	80	75	0
4	125	Luana	Est	70	85	50	8
5	458	Gisele	Est	45	50		16
6	874	Pedro	Mat	55	75	90	0
7	963	André	Est	30		30	20

Formas de renomear as colunas de uma tabela.

Renomeação

Via pares de substituição

```
names(df1)
```

```
# [1] "matricula" "nome"      "curso"     "prova1"
# [5] "prova2"    "prova3"    "faltas"
```

```
# Renomeia nomes de colunas (variáveis).
df1 %>%
    rename("mat." = "matricula",
           "fl" = "faltas",
           "nm" = 2)
```

```
# # A tibble: 7 × 7
#    mat. nm      curso prova1 prova2 prova3    fl
#   <dbl> <chr>   <chr>  <dbl>  <dbl>  <dbl> <dbl>
# 1   256 João    Mat       80     90     80     4
# 2   487 Vanessa Mat       75     75     75     4
# 3   965 Tiago   Est       95     80     75     0
# 4   125 Luana   Est       70     85     50     8
# 5   458 Gisele  Est       45     50     NA    16
# 6   874 Pedro   Mat       55     75     90     0
# 7   963 André   Est       30     NA     30    20
```

Função de transformação de *strings*

```
df1 %>%
    rename_with(.fn = str_to_upper,
                .cols = prova1:prova3) %>%
    head(n = 2)
```

```
# # A tibble: 2 × 7
#   matricula nome    curso PROVA1 PROVA2 PROVA3 faltas
#       <dbl> <chr>   <chr>  <dbl>  <dbl>  <dbl>  <dbl>
# 1       256 João    Mat       80     90     80      4
# 2       487 Vanessa Mat       75     75     75      4
```

```
df1 %>%
    rename_with(.fn = abbreviate, minlength = 2,
                .cols = prova1:faltas) %>%
    head(n = 2)
```

```
# # A tibble: 2 × 7
#   matricula nome    curso    p1    p2    p3    fl
#       <dbl> <chr>   <chr> <dbl> <dbl> <dbl> <dbl>
# 1       256 João    Mat      80    90    80     4
# 2       487 Vanessa Mat      75    75    75     4
```

```
apropos("rename_")
```

```
# [1] "rename_"      "rename_all"   "rename_at"
# [4] "rename_if"    "rename_vars"  "rename_vars_"
# [7] "rename_with"
```

Realocação de colunas

Realocação pelos nomes

```
df1 %>%
    relocate(curso) %>%
    head(n = 2)
```

```
# # A tibble: 2 × 7
#   curso matricula nome    prova1 prova2 prova3 faltas
#   <chr>     <dbl> <chr>    <dbl>  <dbl>  <dbl>  <dbl>
# 1 Mat         256 João        80     90     80      4
# 2 Mat         487 Vanessa     75     75     75      4
```

```
df1 %>%
    relocate(prova1:faltas) %>%
    head(n = 2)
```

```
# # A tibble: 2 × 7
#   prova1 prova2 prova3 faltas matricula nome    curso
#    <dbl>  <dbl>  <dbl>  <dbl>     <dbl> <chr>   <chr>
# 1     80     90     80      4       256 João    Mat
# 2     75     75     75      4       487 Vanessa Mat
```

```
df1 %>%
    relocate(matricula, nome,
             .after = curso) %>%
    head(n = 2)
```

```
# # A tibble: 2 × 7
#   curso matricula nome    prova1 prova2 prova3 faltas
#   <chr>     <dbl> <chr>    <dbl>  <dbl>  <dbl>  <dbl>
# 1 Mat         256 João        80     90     80      4
# 2 Mat         487 Vanessa     75     75     75      4
```

```
df1 %>%
    relocate(matricula, nome,
             .after = last_col()) %>%
    head(n = 2)
```

```
# # A tibble: 2 × 7
#   curso prova1 prova2 prova3 faltas matricula nome
#   <chr>  <dbl>  <dbl>  <dbl>  <dbl>     <dbl> <chr>
# 1 Mat       80     90     80      4       256 João
# 2 Mat       75     75     75      4       487 Vanessa
```

Transformações

	nome	curso	p1	p2	p3	fl
1	João	Mat	80	90	80	4
2	Vanessa	Mat	75	75	75	4
3	Tiago	Est	95	80	75	0
4	Luana	Est	70	85	50	8
5	Gisele	Est	45	50		16
6	Pedro	Mat	55	75	90	0
7	André	Est	30		30	20

criar

	nome	curso	p1	p2	p3	fl	média	condição
1	João	Mat	80	90	80	4	83,3	Apr
2	Vanessa	Mat	75	75	75	4	75,0	Apr
3	Tiago	Est	95	80	75	0	83,3	Apr
4	Luana	Est	70	85	50	8	68,3	Exa
5	Gisele	Est	45	50		16	31,7	Rep
6	Pedro	Mat	55	75	90	0	73,3	Apr
7	André	Est	30		30	20	20,0	Rep

	nome	curso	p1	p2	p3	fl
1	João	Mat	80	90	80	4
2	Vanessa	Mat	75	75	75	4
3	Tiago	Est	95	80	75	0
4	Luana	Est	70	85	50	8
5	Gisele	Est	45	50		16
6	Pedro	Mat	55	75	90	0
7	André	Est	30		30	20

deletar

	nome	p1	p2	p3
1	João	80	90	80
2	Vanessa	75	75	75
3	Tiago	95	80	75
4	Luana	70	85	50
5	Gisele	45	50	
6	Pedro	55	75	90
7	André	30		30

Criação e deleção de variáveis em uma tabela.

Transformações

As operações podem modificar a tabela com a:

1. **Criação** de novas variáveis.
2. **Remoção** de variáveis.
3. **Transformação** de variáveis.

As operações de criação/transformação podem ser:

1. **Matemáticas**: aritméticas, potência, logarítmicas, trigonométricas, etc.
2. **Compartimentação** (*binning*): agrupar em classes.
3. **Conversão** de tipo de valor: i.e. de `int` $\rightarrow$ `str`.
4. **Substituição**: i.e. preencher um valor ausente.

Transformações

Criação de variável

```
df1 %>%
    mutate(media = (prova1 + prova2 + prova3)/3) %>%
    select(prova1:prova3, media)
```

```
# # A tibble: 7 × 4
#   prova1 prova2 prova3 media
#    <dbl>  <dbl>  <dbl> <dbl>
# 1     80     90     80  83.3
# 2     75     75     75  75
# 3     95     80     75  83.3
# 4     70     85     50  68.3
# 5     45     50     NA  NA
# 6     55     75     90  73.3
# 7     30     NA     30  NA
```

```
## Usando operações por LINHA (rowwise)
df1 %>%
    rowwise() %>%
    mutate(media = mean(c(prova1, prova2, prova3))) %>%
    select(prova1:prova3, media)
## Usando c_across
df1 %>%
    rowwise() %>%
    mutate(media = mean(c_across(prova1:prova3))) %>%
    select(prova1:prova3, media)
```

Transformações em várias variáveis

```
df1 %>%
    mutate(across(prova1:prova3,
                  ~replace_na(., 0)))
```

```
# # A tibble: 7 × 7
#   matricula nome    curso prova1 prova2 prova3 faltas
#       <dbl> <chr>   <chr>  <dbl>  <dbl>  <dbl>  <dbl>
# 1       256 João    Mat       80     90     80      4
# 2       487 Vanessa Mat       75     75     75      4
# 3       965 Tiago   Est       95     80     75      0
# 4       125 Luana   Est       70     85     50      8
# 5       458 Gisele  Est       45     50      0     16
# 6       874 Pedro   Mat       55     75     90      0
# 7       963 André   Est       30      0     30     20
```

```
## São abreviações de
df1 %>%
    replace_na(list(prova1 = 0, prova2 = 0, prova3 = 0))
```

Transformações

Transformações dado uma condição

```
## Passa para caixa alta.
df1 %>%
    mutate(across(where(is.character), str_to_upper))
```

```
# # A tibble: 7 × 7
#   matricula nome    curso prova1 prova2 prova3 faltas
#       <dbl> <chr>   <chr>  <dbl>  <dbl>  <dbl>  <dbl>
# 1       256 JOÃO    MAT       80     90     80      4
# 2       487 VANESSA MAT       75     75     75      4
# 3       965 TIAGO   EST       95     80     75      0
# 4       125 LUANA   EST       70     85     50      8
# 5       458 GISELE  EST       45     50     NA     16
# 6       874 PEDRO   MAT       55     75     90      0
# 7       963 ANDRÉ   EST       30     NA     30     20
```

```
df1 %>% mutate(across(where(is.numeric), sqrt))
df1 %>% mutate(across(where(is.numeric), log))
df1 %>% mutate(across(where(is.character), as.factor))
df1 %>% mutate(across(where(is.numeric), as.integer))
```

Transformações dado uma expressão regular

```
## Divide a nota por 10.
df1 %>%
    mutate(across(starts_with("prova"), ~ ./10))
```

```
# # A tibble: 7 × 7
#   matricula nome    curso prova1 prova2 prova3 faltas
#       <dbl> <chr>   <chr>  <dbl>  <dbl>  <dbl>  <dbl>
# 1       256 João    Mat      8      9      8        4
# 2       487 Vanessa Mat      7.5    7.5    7.5      4
# 3       965 Tiago   Est      9.5    8      7.5      0
# 4       125 Luana   Est      7      8.5    5        8
# 5       458 Gisele  Est      4.5    5     NA       16
# 6       874 Pedro   Mat      5.5    7.5    9        0
# 7       963 André   Est      3     NA      3       20
```

Transformações

Cortar valores em classe

```
# Intervalos para corte e rótulos.
inter <- c(0, 40, 70, 100)
condi <- c("reprovado", "exame", "aprovado")

tb_final <- df1 %>%
    mutate(across(starts_with("prova"),
                  ~replace_na(., 0))) %>%
    mutate(media = (prova1 + prova2 + prova3)/3,
           result= cut(media,
                       breaks = inter,
                       labels = condi,
                       right = FALSE,
                       include.lowest = TRUE))
```

```
tb_final %>%
    select(nome, curso,
           media, result)
```

```
# # A tibble: 7 × 4
#   nome    curso media result
#   <chr>   <chr> <dbl> <fct>
# 1 João    Mat    83.3 aprovado
# 2 Vanessa Mat    75   aprovado
# 3 Tiago   Est    83.3 aprovado
# 4 Luana   Est    68.3 exame
# 5 Gisele  Est    31.7 reprovado
# 6 Pedro   Mat    73.3 aprovado
# 7 André   Est    20   reprovado
```

Transformações

Remoção de variáveis

```
tb_final %>%
    mutate(media = NULL,
           result = NULL)
```

```
# # A tibble: 7 × 7
#   matricula nome    curso prova1 prova2 prova3 faltas
#       <dbl> <chr>   <chr>  <dbl>  <dbl>  <dbl>  <dbl>
# 1       256 João    Mat       80     90     80      4
# 2       487 Vanessa Mat       75     75     75      4
# 3       965 Tiago   Est       95     80     75      0
# 4       125 Luana   Est       70     85     50      8
# 5       458 Gisele  Est       45     50      0     16
# 6       874 Pedro   Mat       55     75     90      0
# 7       963 André   Est       30      0     30     20
```

```
tb_final$media <- NULL
tb_final$result <- NULL
tb_final
```

```
# # A tibble: 7 × 7
#   matricula nome    curso prova1 prova2 prova3 faltas
#       <dbl> <chr>   <chr>  <dbl>  <dbl>  <dbl>  <dbl>
# 1       256 João    Mat       80     90     80      4
# 2       487 Vanessa Mat       75     75     75      4
# 3       965 Tiago   Est       95     80     75      0
# 4       125 Luana   Est       70     85     50      8
# 5       458 Gisele  Est       45     50      0     16
# 6       874 Pedro   Mat       55     75     90      0
# 7       963 André   Est       30      0     30     20
```

Rearranjo

- São operações de *reshaping* da tabela.
- Modificam a disposição dos registros.
  - Empilhar ou amontoar um conjunto de variáveis.
  - Desempilhar ou esparramar os níveis de uma variável.

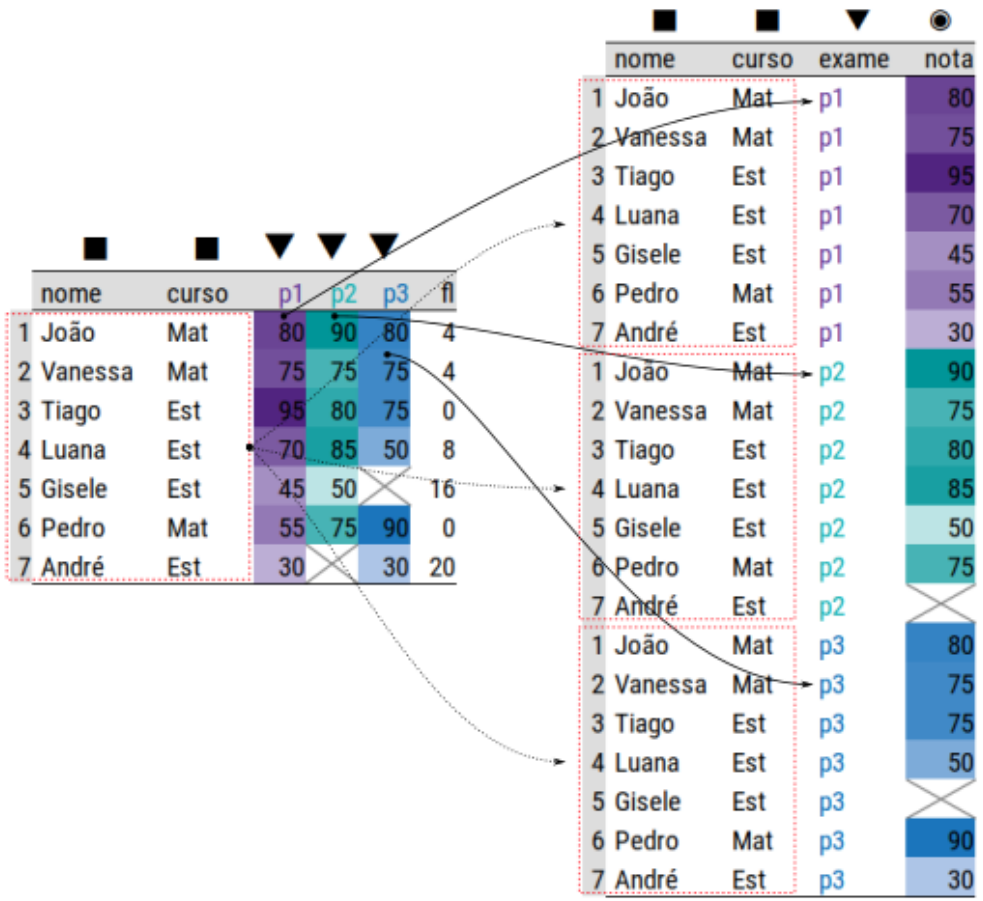

Modificação da disposição com empilhamento.

Rearranjo · Empilhar

```
# Empilhar.
u <- df1 %>%
    pivot_longer(cols = prova1:prova3,
                 names_to = "exame",
                 values_to = "nota")
head(u) %>%
    select(nome, curso, exame, nota)
```

```
# # A tibble: 6 × 4
#   nome    curso exame   nota
#   <chr>   <chr> <chr>  <dbl>
# 1 João    Mat   prova1    80
# 2 João    Mat   prova2    90
# 3 João    Mat   prova3    80
# 4 Vanessa Mat   prova1    75
# 5 Vanessa Mat   prova2    75
# 6 Vanessa Mat   prova3    75
```

```
dim(u)
```

```
# [1] 21  6
```

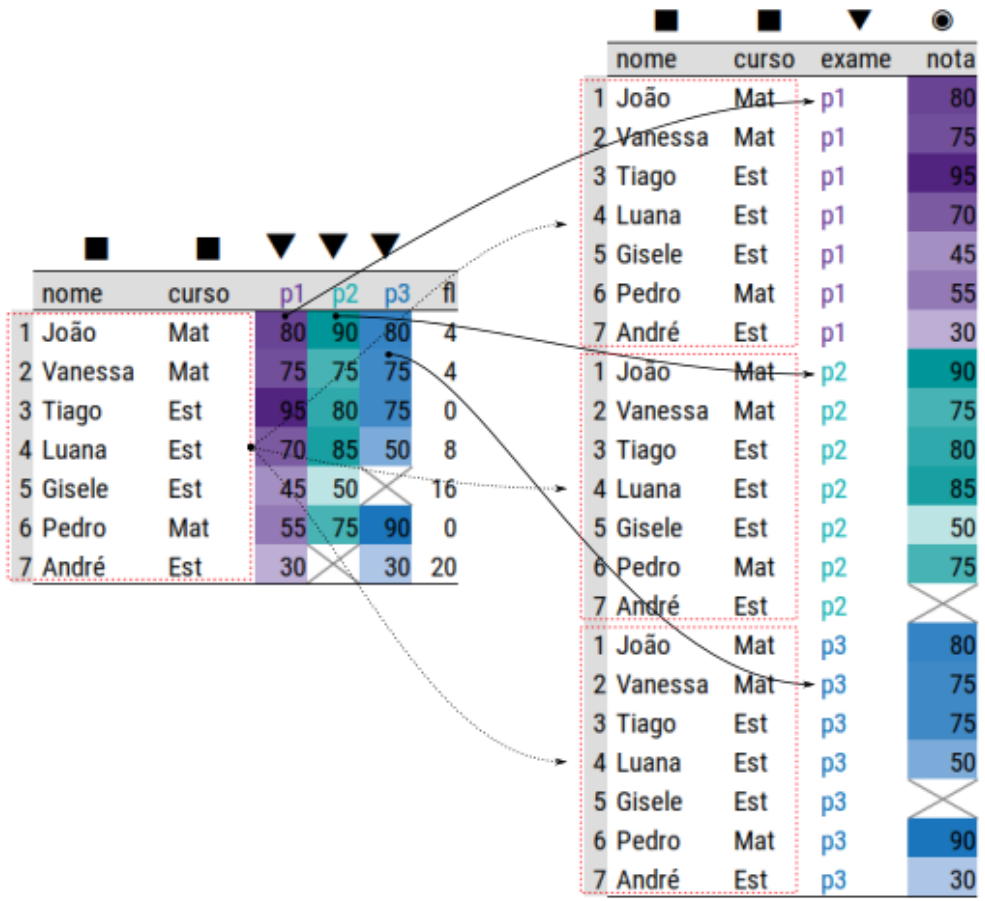

Modificação da disposição com empilhamento.

Rearranjo · Esparramar

```
# Spread = esparramar.
v <- u %>%
    pivot_wider(names_from = "exame",
                values_from = "nota")
head(v)
```

```
# # A tibble: 6 × 7
#   matricula nome    curso faltas prova1 prova2 prova3
#       <dbl> <chr>   <chr>  <dbl>  <dbl>  <dbl>  <dbl>
# 1       256 João    Mat        4     80     90     80
# 2       487 Vanessa Mat        4     75     75     75
# 3       965 Tiago   Est        0     95     80     75
# 4       125 Luana   Est        8     70     85     50
# 5       458 Gisele  Est       16     45     50     NA
# 6       874 Pedro   Mat        0     55     75     90
```

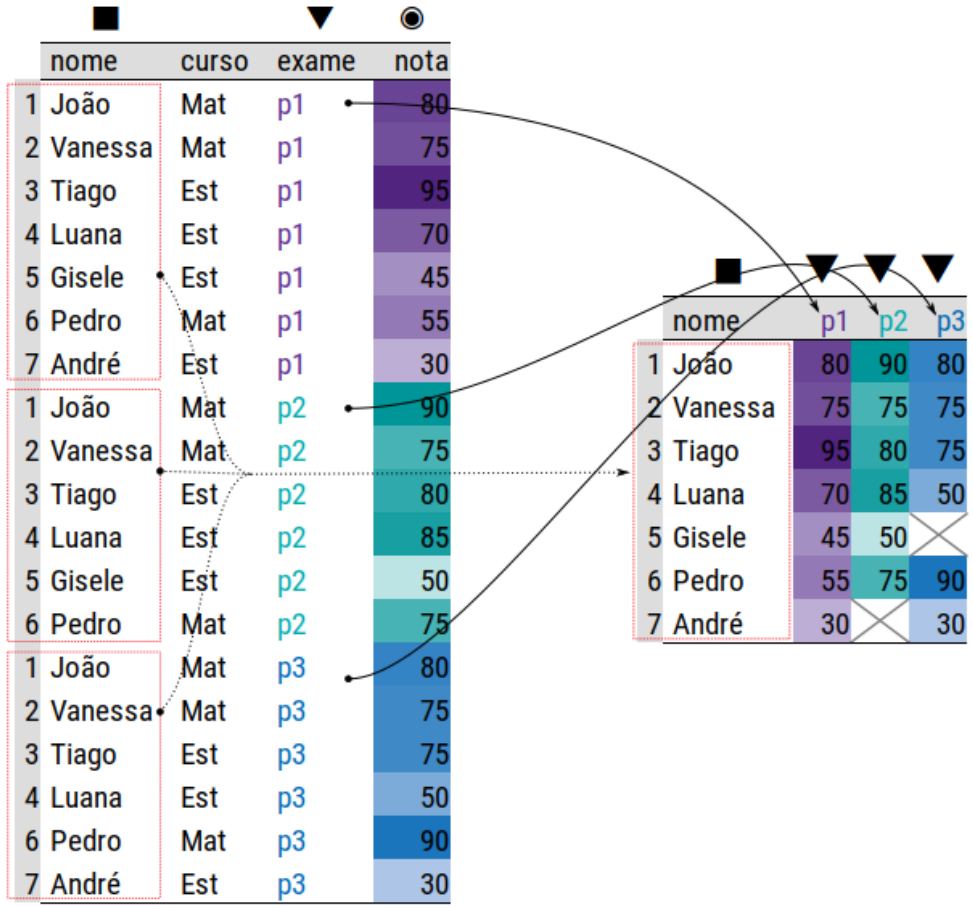

Modificação da disposição com desempilhamento.

Medidas resumo

- Operações para determinar estatísticas descritivas.
  - Soma, média, mediana, quartis, quantis, etc.
  - Variância, desvio-padrão, amplitude, desvio absoluto da mediana, coeficiente de variação, etc.
  - Número de níveis distintos, frequências absolutas/relativas, etc.
- Elas podem ser marginais ou considerar a estratificação conforme uma ou mais variáveis categóricas.
- Podem ser aplicadas em todas as variáveis de um mesmo tipo (homogêneo).

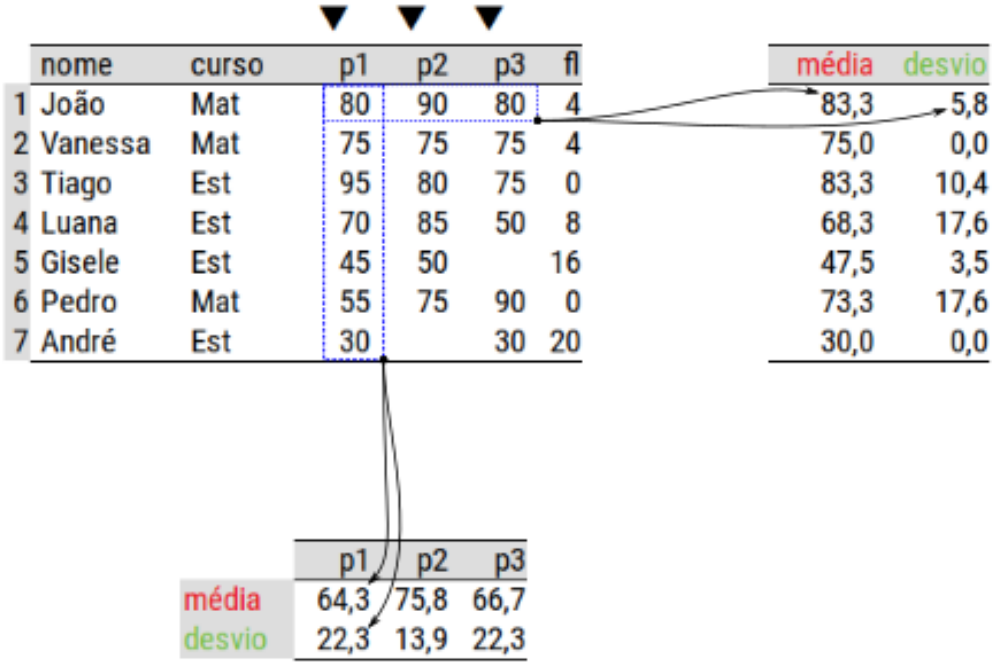

	nome	curso	p1	p2	p3	fl	média	desvio
1	João	Mat	80	90	80	4	83,3	5,8
2	Vanessa	Mat	75	75	75	4	75,0	0,0
3	Tiago	Est	95	80	75	0	83,3	10,4
4	Luana	Est	70	85	50	8	68,3	17,6
5	Gisele	Est	45	50		16	47,5	3,5
6	Pedro	Mat	55	75	90	0	73,3	17,6
7	André	Est	30		30	20	30,0	0,0

	p1	p2	p3
média	64,3	75,8	66,7
desvio	22,3	13,9	22,3

Cálculo de medidas resumo.

Medidas resumo

Uma estatística

```
# Medidas resumo de uma estatística.
df1 %>%
    summarise(soma = sum(prova1),
              media = mean(prova1),
              max = max(prova1),
              sd = sd(prova1))
```

```
# # A tibble: 1 × 4
#    soma media   max    sd
#   <dbl> <dbl> <dbl> <dbl>
# 1   450  64.3    95  22.3
```

Um vetor de estatísticas

```
# Medidas resumo de um vetor de estatísticas.
quantile(df1$prova1, probs = c(0.25, 0.5, 0.75))
```

```
#  25%  50%  75%
# 50.0 70.0 77.5
```

```
fivenum(df1$prova1)
```

```
# [1] 30.0 50.0 70.0 77.5 95.0
```

```
table(df1$curso)
```

```
#
# Est Mat
#   4   3
```

Medidas resumo

Estatísticas definidas pelo usuário

```
df1 %>%
    summarise(CV = 100 * sd(prova1)/mean(prova1))
```

```
# Define uma função para facilitar.
CV <- function(x, ...) {
    100 * sd(x, ...)/mean(x, ...)
}

df1 %>%
    summarise(across(starts_with("prova"),
                     CV, na.rm = TRUE))
```

```
# # A tibble: 1 × 3
#   prova1 prova2 prova3
#    <dbl>  <dbl>  <dbl>
# 1   34.6   18.4   33.4
```

Várias estatísticas para várias variáveis

```
df1 %>%
    summarise(across(prova1:prova3,
                     c(mean, sd), na.rm = TRUE))
```

```
# # A tibble: 1 × 6
#   prova1_1 prova1_2 prova2_1 prova2_2 prova3_1 prova3_2
#      <dbl>    <dbl>    <dbl>    <dbl>    <dbl>    <dbl>
# 1     64.3     22.3     75.8     13.9     66.7     22.3
```

Agregação

- Consiste em aplicar estatísticas em variáveis fazendo a extratificação por outras variáveis.
- São tarefas conhecidas como *split-apply-combine*.
- Ou também chamadas de **GROUP BY**.

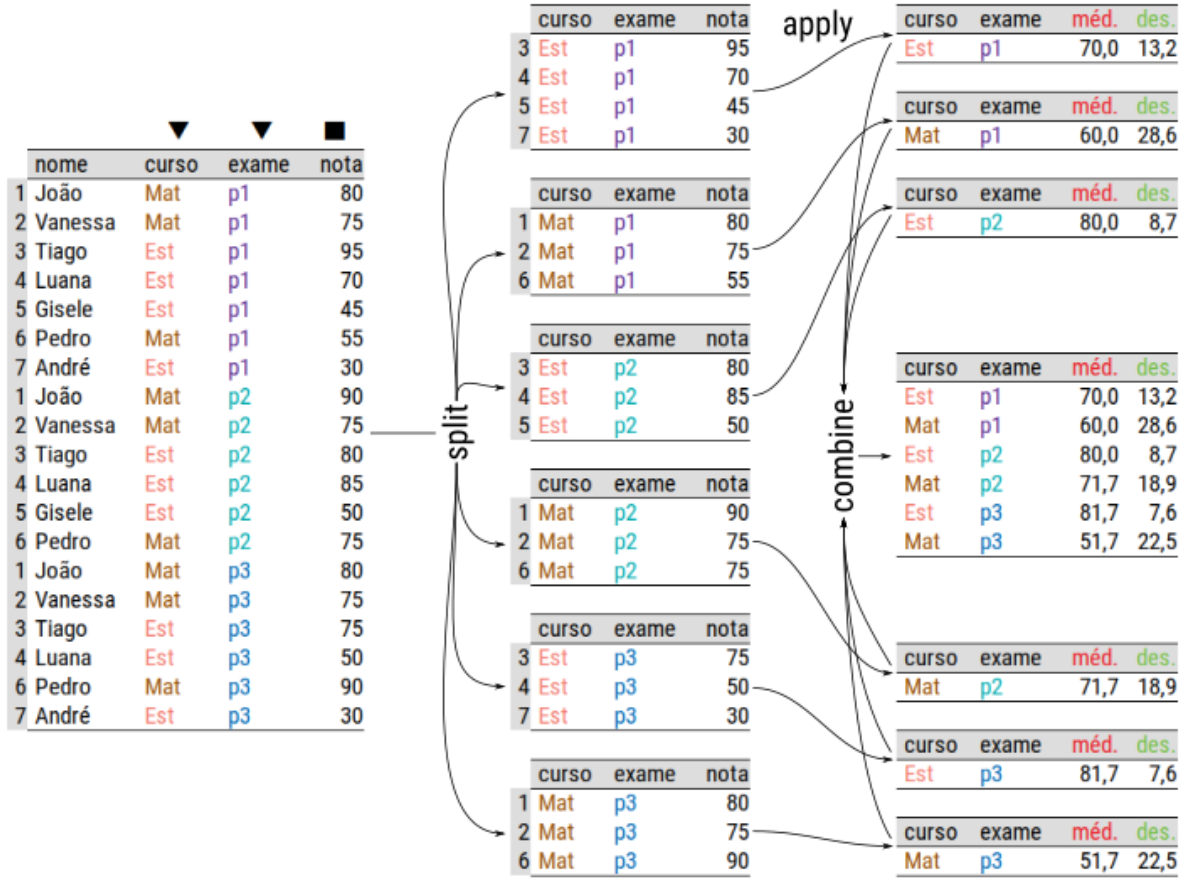

	nome	curso	exame	nota
1	João	Mat	p1	80
2	Vanessa	Mat	p1	75
3	Tiago	Est	p1	95
4	Luana	Est	p1	70
5	Gisele	Est	p1	45
6	Pedro	Mat	p1	55
7	André	Est	p1	30
1	João	Mat	p2	90
2	Vanessa	Mat	p2	75
3	Tiago	Est	p2	80
4	Luana	Est	p2	85
5	Gisele	Est	p2	50
6	Pedro	Mat	p2	75
1	João	Mat	p3	80
2	Vanessa	Mat	p3	75
3	Tiago	Est	p3	75
4	Luana	Est	p3	50
6	Pedro	Mat	p3	90
7	André	Est	p3	30

	curso	exame	nota
3	Est	p1	95
4	Est	p1	70
5	Est	p1	45
7	Est	p1	30

	curso	exame	nota
1	Mat	p1	80
2	Mat	p1	75
6	Mat	p1	55

	curso	exame	nota
3	Est	p2	80
4	Est	p2	85
5	Est	p2	50

	curso	exame	nota
1	Mat	p2	90
2	Mat	p2	75
6	Mat	p2	75

	curso	exame	nota
3	Est	p3	75
4	Est	p3	50
7	Est	p3	30

	curso	exame	nota
1	Mat	p3	80
2	Mat	p3	75
6	Mat	p3	90

curso	exame	méd.	des.
Est	p1	70,0	13,2

curso	exame	méd.	des.
Mat	p1	60,0	28,6

curso	exame	méd.	des.
Est	p2	80,0	8,7

curso	exame	méd.	des.
Mat	p2	71,7	18,9

curso	exame	méd.	des.
Est	p3	81,7	7,6

curso	exame	méd.	des.
Mat	p3	51,7	22,5

curso	exame	méd.	des.
Est	p1	70,0	13,2
Mat	p1	60,0	28,6
Est	p2	80,0	8,7
Mat	p2	71,7	18,9
Est	p3	81,7	7,6
Mat	p3	51,7	22,5

Agregação de uma tabela.

Agregação

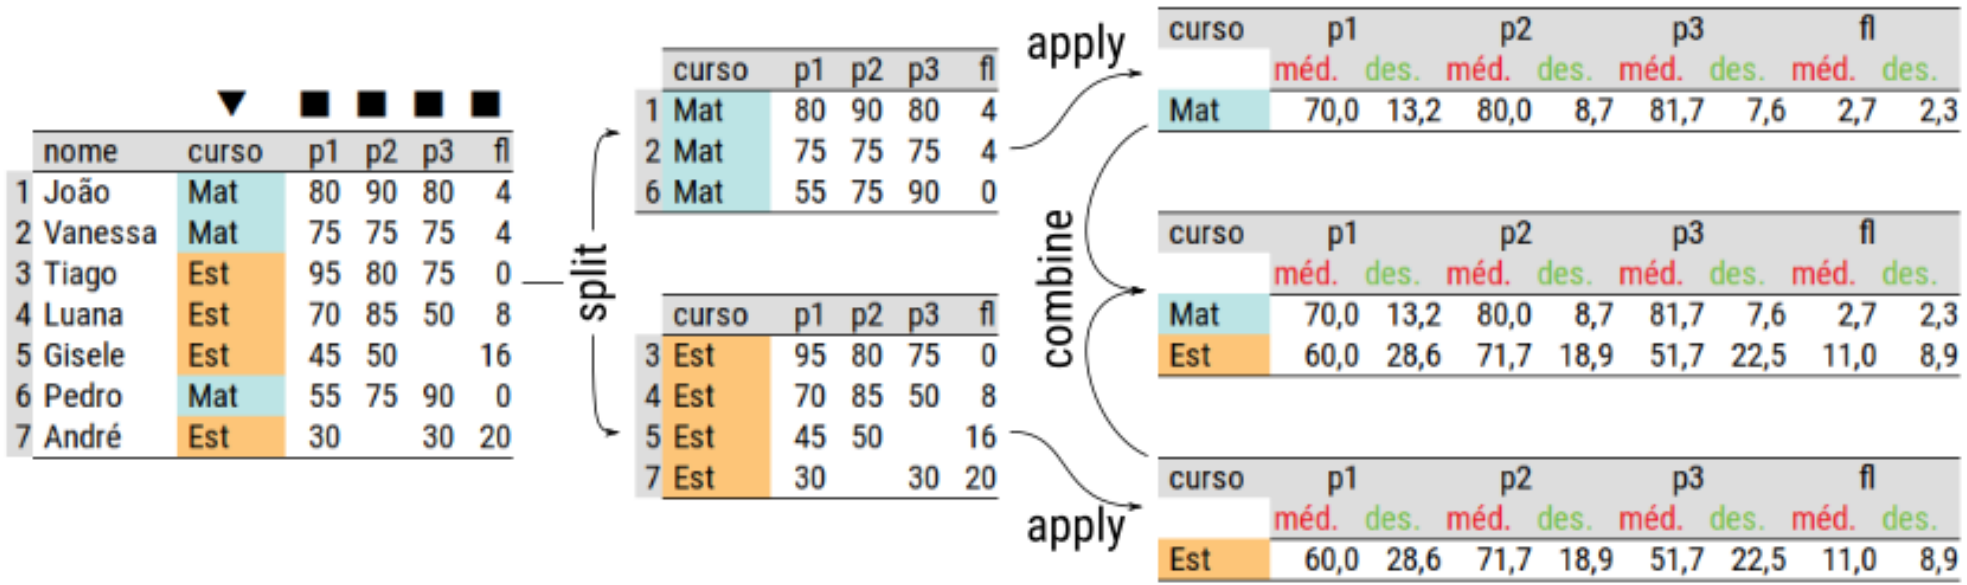

	nome	curso	p1	p2	p3	fl
1	João	Mat	80	90	80	4
2	Vanessa	Mat	75	75	75	4
3	Tiago	Est	95	80	75	0
4	Luana	Est	70	85	50	8
5	Gisele	Est	45	50		16
6	Pedro	Mat	55	75	90	0
7	André	Est	30		30	20

	curso	p1	p2	p3	fl
1	Mat	80	90	80	4
2	Mat	75	75	75	4
6	Mat	55	75	90	0

	curso	p1	p2	p3	fl
3	Est	95	80	75	0
4	Est	70	85	50	8
5	Est	45	50		16
7	Est	30		30	20

curso	p1		p2		p3		fl	
	méd.	des.	méd.	des.	méd.	des.	méd.	des.
Mat	70,0	13,2	80,0	8,7	81,7	7,6	2,7	2,3

curso	p1		p2		p3		fl	
	méd.	des.	méd.	des.	méd.	des.	méd.	des.
Mat	70,0	13,2	80,0	8,7	81,7	7,6	2,7	2,3
Est	60,0	28,6	71,7	18,9	51,7	22,5	11,0	8,9

curso	p1		p2		p3		fl	
	méd.	des.	méd.	des.	méd.	des.	méd.	des.
Est	60,0	28,6	71,7	18,9	51,7	22,5	11,0	8,9

Agregação de uma tabela.

Agregação

Cálculo de frequências

```
# Registros por curso.
df1 %>%
    count(curso)
```

```
# # A tibble: 2 × 2
#   curso     n
#   <chr> <int>
# 1 Est       4
# 2 Mat       3
```

```
## Aprovados/reprovados por curso
df1 %>%
    mutate(across(prova1:prova3, ~replace_na(., 0))) %>%
    mutate(media = (prova1 + prova2 + prova3)/3,
           cond = ifelse(media >= 70, "Apr", "Rep")) %>%
    count(curso, cond)
```

```
# # A tibble: 3 × 3
#   curso cond      n
#   <chr> <chr> <int>
# 1 Est   Apr       1
# 2 Est   Rep       3
# 3 Mat   Apr       3
```

Agregação

Medidas descritivas resumo

```
## Nota média por curso em cada avaliação.
df1 %>%
    group_by(curso) %>%
    summarise(across(prova1:prova3, mean, na.rm = TRUE))
```

```
# # A tibble: 2 × 4
#   curso prova1 prova2 prova3
#   <chr>  <dbl>  <dbl>  <dbl>
# 1 Est       60   71.7   51.7
# 2 Mat       70   80     81.7
```

```
## Média final por curso.
df1 %>%
    mutate(across(prova1:prova3, ~replace_na(., 0))) %>%
    mutate(media = (prova1 + prova2 + prova3)/3) %>%
    group_by(curso) %>%
    summarise(med = mean(media), sd = sd(media))
```

```
# # A tibble: 2 × 3
#   curso   med    sd
#   <chr> <dbl> <dbl>
# 1 Est    50.8 29.9
# 2 Mat    77.2  5.36
```

Agregação

Usando o formato longo

```
dfl <- df1 %>%
    pivot_longer(cols = prova1:prova3,
                 names_to = "prova",
                 values_to = "nota") %>%
    replace_na(list(nota = 0))
head(dfl, n = 4)
```

```
# # A tibble: 4 × 6
#   matricula nome    curso faltas prova   nota
#       <dbl> <chr>   <chr>  <dbl> <chr>  <dbl>
# 1       256 João    Mat        4 prova1    80
# 2       256 João    Mat        4 prova2    90
# 3       256 João    Mat        4 prova3    80
# 4       487 Vanessa Mat        4 prova1    75
```

```
dfl %>%
    group_by(prova, curso) %>%
    summarise(media = mean(nota), dp = sd(nota))
```

```
# # A tibble: 6 × 4
# # Groups:   prova [3]
#   prova  curso media    dp
#   <chr>  <chr> <dbl> <dbl>
# 1 prova1 Est    60   28.6
# 2 prova1 Mat    70   13.2
# 3 prova2 Est    53.8 39.0
# 4 prova2 Mat    80    8.66
# 5 prova3 Est    38.8 31.7
# 6 prova3 Mat    81.7  7.64
```

```
dfl %>%
    group_by(nome) %>%
    summarise(media = mean(nota), dp = sd(nota),
              faltas = unique(faltas),
              cond = ifelse(media > 70, "Apr", "Rep"))
```

```
# # A tibble: 7 × 5
#   nome    media    dp faltas cond
#   <chr>   <dbl> <dbl>  <dbl> <chr>
# 1 André    20   17.3      20 Rep
# 2 Gisele   31.7 27.5      16 Rep
# 3 João     83.3  5.77      4 Apr
# 4 Luana    68.3 17.6       8 Rep
# 5 Pedro    73.3 17.6       0 Apr
# 6 Tiago    83.3 10.4       0 Apr
# 7 Vanessa  75    0          4 Apr
```

Agregação

- Uma vez que uma tabela é agrupada, várias informações e métodos estão disponíveis.
- Isso permite criar uma lista de tabelas para operar com programação funcional.

```
## Cria uma tabela de dados agrupados.
u <- df1 %>%
    group_by(curso)
u
```

```
# # A tibble: 7 × 7
# # Groups:   curso [2]
#   matricula nome    curso prova1 prova2 prova3 faltas
#       <dbl> <chr>   <chr>  <dbl>  <dbl>  <dbl>  <dbl>
# 1       256 João    Mat       80     90     80      4
# 2       487 Vanessa Mat       75     75     75      4
# 3       965 Tiago   Est       95     80     75      0
# 4       125 Luana   Est       70     85     50      8
# 5       458 Gisele  Est       45     50     NA     16
# 6       874 Pedro   Mat       55     75     90      0
# 7       963 André   Est       30     NA     30     20
```

```
## Inspeciona os métodos disponíveis.
class(u)
methods(class = "grouped_df")
## Usa alguns dos métodos.
n_groups(u)
group_vars(u)
group_size(u)
group_indices(u)
```

```
## Cria uma lista de tabelas.
u <- df1 %>%
    group_split(curso)
glimpse(u)
```

```
# list<tibble[,7]> [1:2]
# $ : tibble [4 × 7] (S3: tbl_df/tbl/data.frame)
# $ : tibble [3 × 7] (S3: tbl_df/tbl/data.frame)
# @ ptype: tibble [0 × 7] (S3: tbl_df/tbl/data.frame)
```

Concatenação

- A concatenação permite adicionar novas observações a uma tabela ou novas variáveis.
- Seja por linha ou colunas, entradas com `NA` são criadas para os índices que não foram especificados.

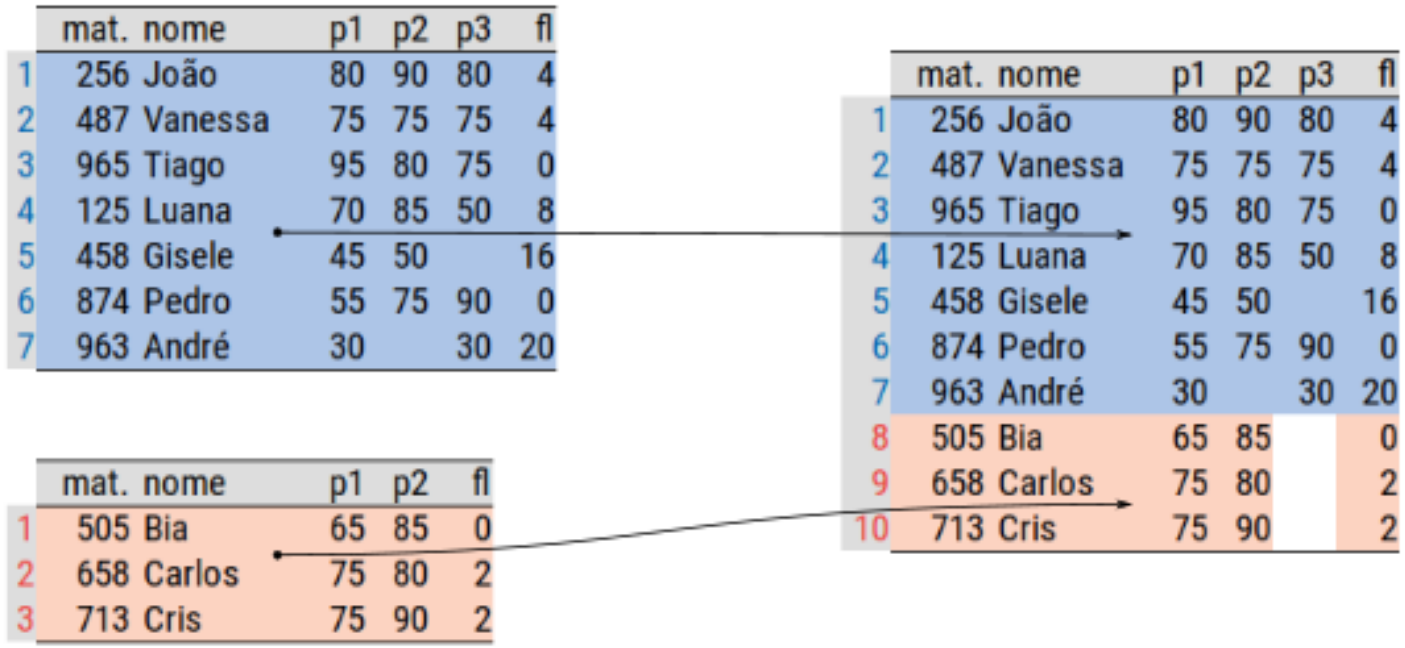

	mat.	nome	p1	p2	p3	fl
1	256	João	80	90	80	4
2	487	Vanessa	75	75	75	4
3	965	Tiago	95	80	75	0
4	125	Luana	70	85	50	8
5	458	Gisele	45	50		16
6	874	Pedro	55	75	90	0
7	963	André	30		30	20

	mat.	nome	p1	p2	fl
1	505	Bia	65	85	0
2	658	Carlos	75	80	2
3	713	Cris	75	90	2

	mat.	nome	p1	p2	p3	fl
1	256	João	80	90	80	4
2	487	Vanessa	75	75	75	4
3	965	Tiago	95	80	75	0
4	125	Luana	70	85	50	8
5	458	Gisele	45	50		16
6	874	Pedro	55	75	90	0
7	963	André	30		30	20
8	505	Bia	65	85		0
9	658	Carlos	75	80		2
10	713	Cris	75	90		2

Concatenação de duas tabelas.

Concatenação

De linhas (vertical)

```
## Concatenação na vertical (pilha)
df2 <- tibble(
    matricula = c(505, 658, 713),
    nome = c("Bia", "Carlos", "Cris"),
    prova1 = c(65, 75, 75),
    prova2 = c(85, 80, 90),
    faltas = c(0, 2, 2))
bind_rows(df1, df2)
```

```
# # A tibble: 10 × 7
#    matricula nome    curso prova1 prova2 prova3 faltas
#        <dbl> <chr>   <chr>  <dbl>  <dbl>  <dbl>  <dbl>
#  1       256 João    Mat       80     90     80      4
#  2       487 Vanessa Mat       75     75     75      4
#  3       965 Tiago   Est       95     80     75      0
#  4       125 Luana   Est       70     85     50      8
#  5       458 Gisele  Est       45     50     NA     16
#  6       874 Pedro   Mat       55     75     90      0
#  7       963 André   Est       30     NA     30     20
#  8       505 Bia     <NA>      65     85     NA      0
#  9       658 Carlos  <NA>      75     80     NA      2
# 10       713 Cris    <NA>      75     90     NA      2
```

De colunas (horizontal)

```
## Concatenação na horizontal (fila)
bind_cols(df1[, c(1:3)],
          df1[, c(6:7)])
```

```
# # A tibble: 7 × 5
#   matricula nome    curso prova3 faltas
#       <dbl> <chr>   <chr>  <dbl>  <dbl>
# 1       256 João    Mat       80      4
# 2       487 Vanessa Mat       75      4
# 3       965 Tiago   Est       75      0
# 4       125 Luana   Est       50      8
# 5       458 Gisele  Est       NA     16
# 6       874 Pedro   Mat       90      0
# 7       963 André   Est       30     20
```

Junções

- Junções permitem parear dados de tabelas separadas quando elas possuem uma chave (ou chave primária).
- As operações de junção podem ser inicialmente de 4 tipos:
  - Junção por interseção (*inner join*).
  - Junção por união (*full join*).
  - Junção à esquerda (*left join*).
  - Junção à direita (*right join*).
  - Existe também os *exclusive joins*.

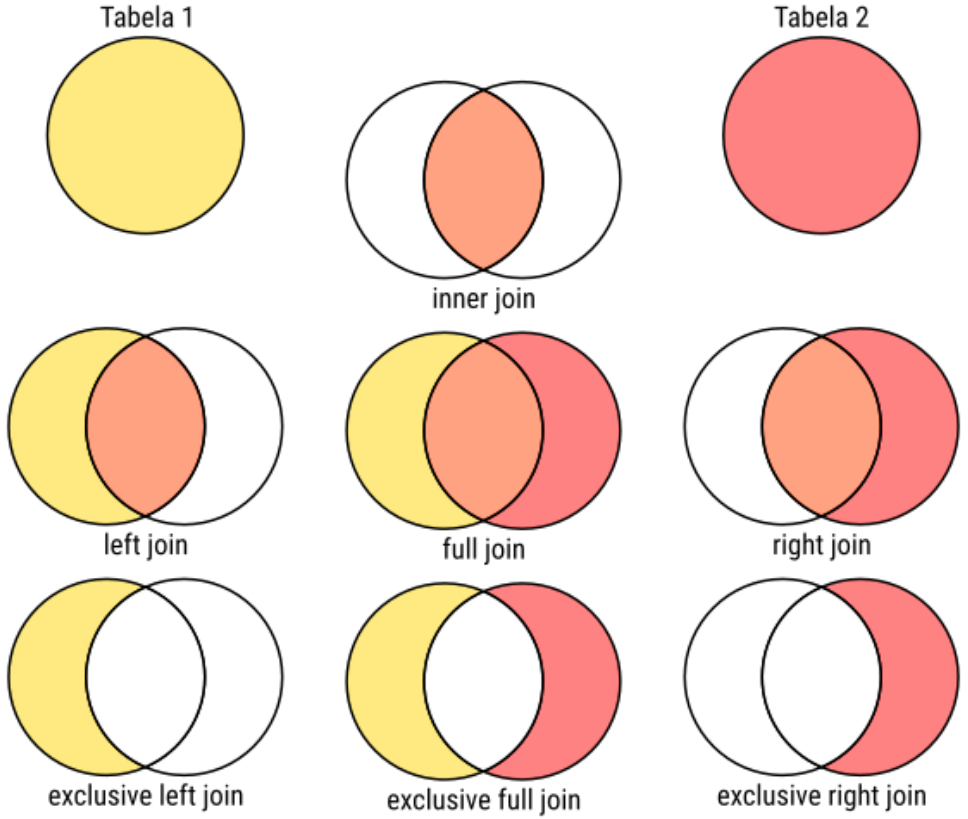

Tipos de junções de tabelas ilustrado com diagramas de Veen.

Junções

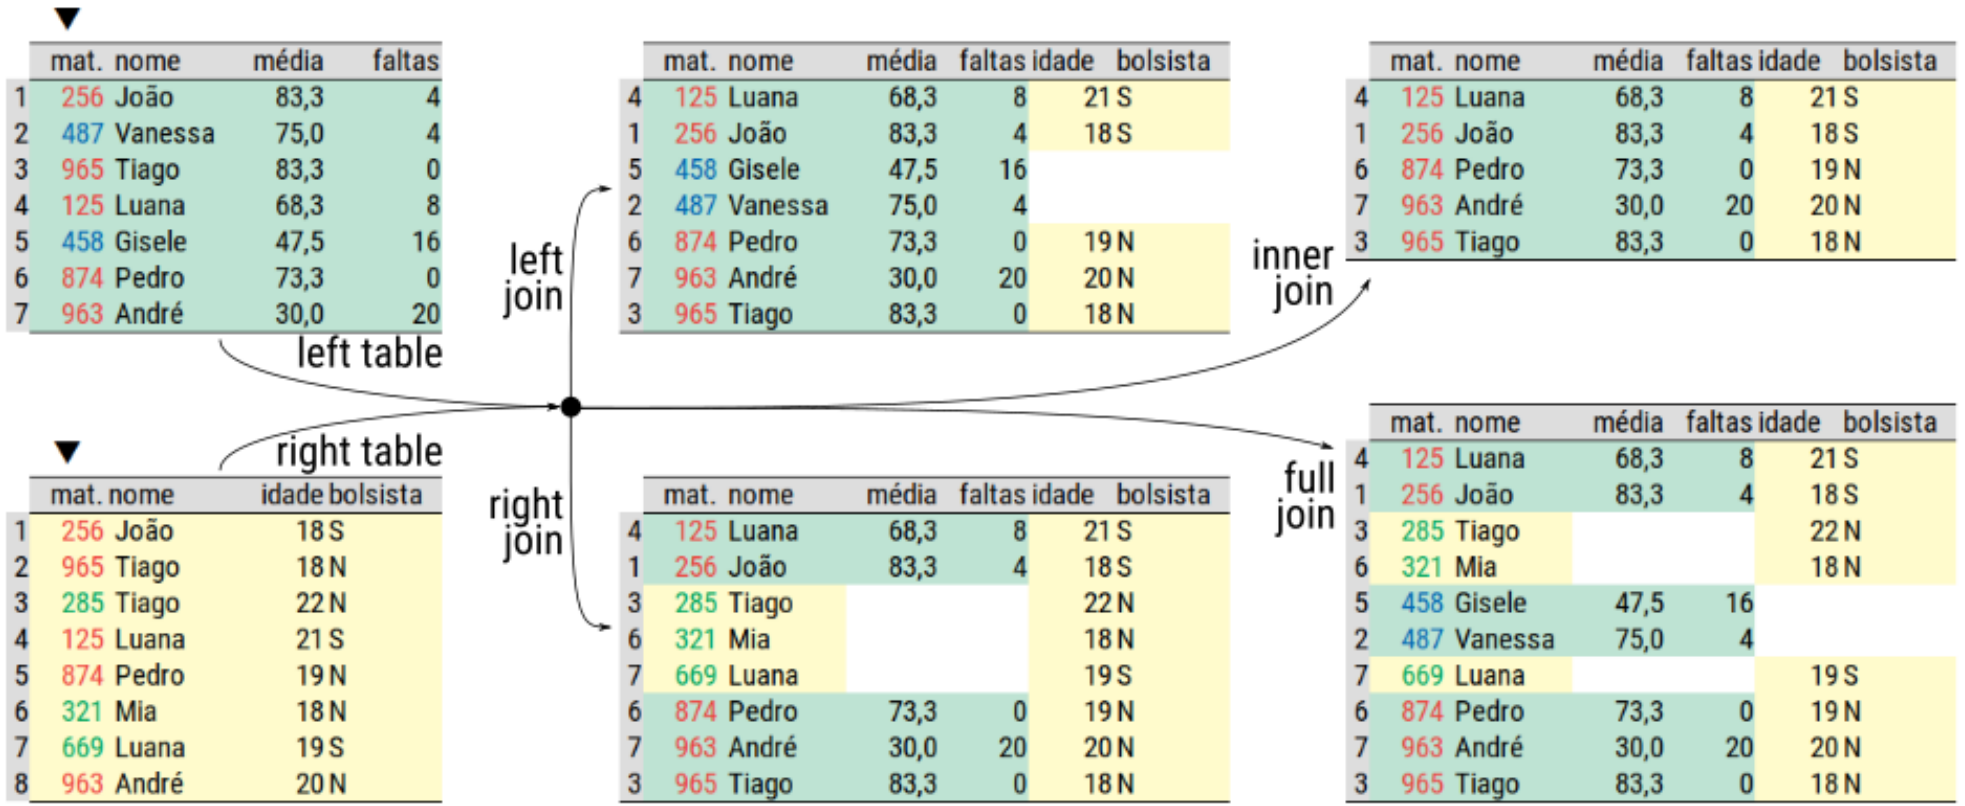

	mat.	nome	média	faltas
1	256	João	83,3	4
2	487	Vanessa	75,0	4
3	965	Tiago	83,3	0
4	125	Luana	68,3	8
5	458	Gisele	47,5	16
6	874	Pedro	73,3	0
7	963	André	30,0	20

	mat.	nome	idade	bolsista
1	256	João	18	S
2	965	Tiago	18	N
3	285	Tiago	22	N
4	125	Luana	21	S
5	874	Pedro	19	N
6	321	Mia	18	N
7	669	Luana	19	S
8	963	André	20	N

	mat.	nome	média	faltas	idade	bolsista
4	125	Luana	68,3	8	21	S
1	256	João	83,3	4	18	S
5	458	Gisele	47,5	16		
2	487	Vanessa	75,0	4		
6	874	Pedro	73,3	0	19	N
7	963	André	30,0	20	20	N
3	965	Tiago	83,3	0	18	N

	mat.	nome	média	faltas	idade	bolsista
4	125	Luana	68,3	8	21	S
1	256	João	83,3	4	18	S
6	874	Pedro	73,3	0	19	N
7	963	André	30,0	20	20	N
3	965	Tiago	83,3	0	18	N

	mat.	nome	média	faltas	idade	bolsista
4	125	Luana	68,3	8	21	S
1	256	João	83,3	4	18	S
3	285	Tiago			22	N
6	321	Mia			18	N
5	458	Gisele	47,5	16		
2	487	Vanessa	75,0	4		
7	669	Luana			19	S
6	874	Pedro	73,3	0	19	N
7	963	André	30,0	20	20	N
3	965	Tiago	83,3	0	18	N

Junções de tabelas do tipo inclusivas.

Junções

```
## Informações de cadastro dos alunos
## em outra base de dados.
df_extra <- tribble(
    ~mat,     ~nome, ~idade, ~bolsista,
     256,  'João'  ,     18,        "S",
     965,  'Tiago' ,     18,        "N",
     285,  'Tiago' ,     22,        "N",
     125,  'Luana' ,     21,        "S",
     874,  'Pedro' ,     19,        "N",
     321,  'Mia'   ,     18,        "N",
     669,  'Luana' ,     19,        "S",
     963,  'André' ,     20,        "N",
)
```

```
## Full join = união.
full_join(df1, df_extra,
          by = c("matricula" = "mat", "nome")) %>%
    arrange(matricula)
```

```
# # A tibble: 10 × 9
#    matricula nome    curso prova1 prova2 prova3 faltas idade bolsista
#        <dbl> <chr>   <chr>  <dbl>  <dbl>  <dbl>  <dbl> <dbl> <chr>
#  1       125 Luana   Est       70     85     50      8    21 S
#  2       256 João    Mat       80     90     80      4    18 S
#  3       285 Tiago   <NA>      NA     NA     NA     NA    22 N
#  4       321 Mia     <NA>      NA     NA     NA     NA    18 N
#  5       458 Gisele  Est       45     50     NA     16    NA <NA>
#  6       487 Vanessa Mat       75     75     75      4    NA <NA>
#  7       669 Luana   <NA>      NA     NA     NA     NA    19 S
#  8       874 Pedro   Mat       55     75     90      0    19 N
#  9       963 André   Est       30     NA     30     20    20 N
# 10       965 Tiago   Est       95     80     75      0    18 N
```

Junções

```
## Inner join = intersecção.
inner_join(df1, df_extra,
           by = c("matricula" = "mat", "nome")) %>%
    arrange(matricula)
```

```
# # A tibble: 5 × 9
#   matricula nome  curso prova1 prova2 prova3 faltas idade bolsista
#       <dbl> <chr> <chr>  <dbl>  <dbl>  <dbl>  <dbl> <dbl> <chr>
# 1       125 Luana Est       70     85     50      8    21 S
# 2       256 João  Mat       80     90     80      4    18 S
# 3       874 Pedro Mat       55     75     90      0    19 N
# 4       963 André Est       30     NA     30     20    20 N
# 5       965 Tiago Est       95     80     75      0    18 N
```

```
# Os da 2º que não aparecem na 1º.
anti_join(df1, df_extra,
          by = c("matricula" = "mat", "nome")) %>%
    arrange(matricula)
```

```
# # A tibble: 2 × 7
#   matricula nome    curso prova1 prova2 prova3 faltas
#       <dbl> <chr>   <chr>  <dbl>  <dbl>  <dbl>  <dbl>
# 1       458 Gisele  Est       45     50     NA     16
# 2       487 Vanessa Mat       75     75     75      4
```

Junções

```
## Todos os que estão na 1º tabela
left_join(df1, df_extra, by = c("matricula" = "mat", "nome")) %>%
    arrange(matricula)
```

```
# # A tibble: 7 × 9
#   matricula nome    curso prova1 prova2 prova3 faltas idade bolsista
#       <dbl> <chr>   <chr>  <dbl>  <dbl>  <dbl>  <dbl> <dbl> <chr>
# 1       125 Luana   Est       70     85     50      8    21 S
# 2       256 João    Mat       80     90     80      4    18 S
# 3       458 Gisele  Est       45     50     NA     16    NA <NA>
# 4       487 Vanessa Mat       75     75     75      4    NA <NA>
# 5       874 Pedro   Mat       55     75     90      0    19 N
# 6       963 André   Est       30     NA     30     20    20 N
# 7       965 Tiago   Est       95     80     75      0    18 N
```

```
## Todos os que estão na 2º tabela
right_join(df1, df_extra, by = c("matricula" = "mat", "nome")) %>%
    arrange(matricula)
```

```
# # A tibble: 8 × 9
#   matricula nome  curso prova1 prova2 prova3 faltas idade bolsista
#       <dbl> <chr> <chr>  <dbl>  <dbl>  <dbl>  <dbl> <dbl> <chr>
# 1       125 Luana Est       70     85     50      8    21 S
# 2       256 João  Mat       80     90     80      4    18 S
# 3       285 Tiago <NA>      NA     NA     NA     NA    22 N
# 4       321 Mia   <NA>      NA     NA     NA     NA    18 N
# 5       669 Luana <NA>      NA     NA     NA     NA    19 S
# 6       874 Pedro Mat       55     75     90      0    19 N
# 7       963 André Est       30     NA     30     20    20 N
# 8       965 Tiago Est       95     80     75      0    18 N
```

Extra · Funções para descrição geral dos dados

```
Hmisc::describe(iris)
psych::describe(iris)
skimr::skim(iris)
summarytools::descr(iris)
summarytools::dfSummary(iris)
```

```
Hmisc::describe(df1)
```

```
# df1
#
#  7  Variables      7  Observations
# --------------------------------------------------------------------------------
# matricula
#        n  missing distinct     Info     Mean      Gmd
#        7        0        7        1    589.7    414.3
#
# lowest : 125 256 458 487 874, highest: 458 487 874 963 965
#
# Value        125   256   458   487   874   963   965
# Frequency      1     1     1     1     1     1     1
# Proportion 0.143 0.143 0.143 0.143 0.143 0.143 0.143
# --------------------------------------------------------------------------------
# nome
#        n  missing distinct
#        7        0        7
#
# lowest : André   Gisele  João    Luana   Pedro
# highest: João    Luana   Pedro   Tiago   Vanessa
#
# Value        André  Gisele    João   Luana   Pedro   Tiago Vanessa
# Frequency        1       1       1       1       1       1       1
# Proportion   0.143   0.143   0.143   0.143   0.143   0.143   0.143
# --------------------------------------------------------------------------------
# curso
#        n  missing distinct
#        7        0        2
#
```

Exercícios para usar o {dplyr}

- Ler os dados em http://leg.ufpr.br/~walmes/data/ninfas.txt.
- Ordenação.
  1. Ordenar pelo valor do terço `superior`.
  2. Ordenar pelo valor do terço `medio` de forma descrescente.
  3. Ordenar pelas datas $>$ variedade $>$ bloco.
- Filtros.
  1. Filtrar só para a variedade `BRS 245 RR`.
  2. Filtrar só para a variedade `BRS 245 RR` e `EMBRAPA 48`.
  3. Filtrar só para variedades diferentes de `EMBRAPA 48`.
  4. Filtrar quando `superior` for maior do que 30 e `inferior` for maior do que 20.
  5. Filtrar para `medio` entre 20 e 50.
  6. Filtrar para avaliações entre 2009-12-24 e 2010-01-11.
  7. Filtrar para a soma dos terços maior que 100.

Observações:

- Os dados se referem às contagens de ninfas (larvas de insetos) nos terços de plantas de soja
- O termo "terço" se refere a cada uma das três partes da planta: superior, médio, inferior

Exercícios para usar o {dplyr}

- Fatias.
  1. As linhas 34, 74, 23 e 41.
  2. As 10 primeiras linhas.
  3. Da linha 50 até a 63.
  4. As últimas 10 linhas.
  5. Remover as 100 primeiras linhas.
- Amostragem.
  1. Uma amostra de 30 linhas.
  2. Uma amostra de 30 linhas com reposição.
  3. Uma amostra de 10% das linhas.
- Seleção de variáveis.
  1. Selecionar apenas os terços.
  2. Remover a variável bloco.
  3. Mudar a ordem das colunas finais para `inferior`, `medio` e `superior`.
  4. Manter as variáveis com nome terminado em `rior`.
- Modificação/criação de variáveis.
  1. Criar a variável total somando os terços.
  2. Criar a diferença entre o terço superior e inferior.
  3. Converter bloco e variedade para fator.
  4. Criar a raiz quadrada do número de ninfas em cada terço.

Exercícios para usar o {dplyr}

- Renomear.
  1. Renomear variedade para tratamento.
  2. Renomear os terços para versões abreviadas com 3 digitos.
  3. Passar todas as variáveis para caixa alta.
  4. Abreviar todas as variáveis para nomes com 3 digitos.
- Medidas descritivas gerais.
  1. Total de ninfas no terço superior.
  2. Total de ninfas em cada um dos terços.
  3. Média e desvio-padrão de ninfas em cada terço.
- Medidas descritivas por extrato.
  1. Total de registros por variedade.
  2. Total de registros por data.
  3. Total de registros por variedade e data.
  4. Total de ninfas no terço superior por data.
  5. Total de ninfas nos 3 terços juntos por data.
  6. Total de ninfas nos 3 terços juntos por variedade, ordene no final.
  7. Total de ninfas nos 3 terços juntos por data e variedade. Guardar em objeto para usar a seguir.
  8. A variedade com mais ninfas em cada data.
  9. A data com mais ninfas em cada variedade.